Détection d'anomalies

Haytham Elghazel

Pôle Data Science, équipe DM2L

Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Applications

Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Applications

- Intrusions réseau.

Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Applications

- Intrusions réseau.
- Fraude à la carte de crédit.

Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Applications

- Intrusions réseau.
- Fraude à la carte de crédit.
- Surveillance.

Détection d'anomalies

Identifier les instances ayant un comportement non conforme.



Applications

- Intrusions réseau.
- Fraude à la carte de crédit.
- Surveillance.
- Assurance.

Détection d'anomalies

- Supprimer ou modifier des observations atypiques au regard d'un modèle, sans justification, serait contraire à l'éthique.

Détection d'anomalies

- Supprimer ou modifier des observations atypiques au regard d'un modèle, sans justification, serait contraire à l'éthique.
- L'objectif est avant tout de les identifier.

Détection d'anomalies

- Supprimer ou modifier des observations atypiques au regard d'un modèle, sans justification, serait contraire à l'éthique.
- L'objectif est avant tout de les identifier.
- Elles peuvent être la conséquence d'une erreur de mesure ou de libellé, à confirmer.

Détection d'anomalies

- Supprimer ou modifier des observations atypiques au regard d'un modèle, sans justification, serait contraire à l'éthique.
- L'objectif est avant tout de les identifier.
- Elles peuvent être la conséquence d'une erreur de mesure ou de libellé, à confirmer.
- Selon le contexte, elles peuvent aussi correspondre à une défaillance, une tentative de fraude ou une intrusion.

Outliers et nouveautés

Détection d'outliers — outlier detection

Les données d'apprentissage contiennent des observations atypiques. L'objectif est de repérer les anomalies dans le jeu de données initial, notamment en distinguant les régions denses et les observations isolées.

Outliers et nouveautés

Détection d'outliers — outlier detection

Les données d'apprentissage contiennent des observations atypiques. L'objectif est de repérer les anomalies dans le jeu de données initial, notamment en distinguant les régions denses et les observations isolées.

Détection de nouveautés — novelty detection

Le jeu d'apprentissage n'est pas pollué par des anomalies. L'objectif est de détecter des anomalies dans les données futures, non observées pendant l'apprentissage.

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.

Approches non supervisées

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.
- Les anomalies constituent la classe rare.

Approches non supervisées

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.
- Les anomalies constituent la classe rare.
- Données déséquilibrées.

Approches non supervisées

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.
- Les anomalies constituent la classe rare.
- Données déséquilibrées.

Approches non supervisées

- Aucune étiquette fournie.

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.
- Les anomalies constituent la classe rare.
- Données déséquilibrées.

Approches non supervisées

- Aucune étiquette fournie.
- Données normales et anomalies dans l'apprentissage.

Plusieurs approches

Approches supervisées

- Étiquettes pour les instances normales et les anomalies.
- Les anomalies constituent la classe rare.
- Données déséquilibrées.

Approches non supervisées

- Aucune étiquette fournie.
- Données normales et anomalies dans l'apprentissage.
- Les anomalies sont très rares.

Approches fondées sur le voisinage

- L'isolement d'une observation est apprécié par la proximité des points de son voisinage.

Approches fondées sur le voisinage

- L'isolement d'une observation est apprécié par la proximité des points de son voisinage.
- Exemple : **Local Outlier Factor (LOF)**.

Approches fondées sur le voisinage

- L'isolement d'une observation est apprécié par la proximité des points de son voisinage.
- Exemple : **Local Outlier Factor (LOF)**.
- LOF compare la densité locale d'une observation à celle de ses voisins.

Approches fondées sur le voisinage

- L'isolement d'une observation est apprécié par la proximité des points de son voisinage.
- Exemple : **Local Outlier Factor (LOF)**.
- LOF compare la densité locale d'une observation à celle de ses voisins.
- La densité locale est évaluée à partir des k plus proches voisins. Une densité beaucoup plus faible que celle des voisins signale une observation atypique.

LOF : 1. Trouver les voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$D_k(x)$: distance au k-ième voisin. $N_k(x)$: ensemble des voisins considérés.

LOF : 1. Trouver les voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$D_k(x)$: distance au k-ième voisin. $N_k(x)$: ensemble des voisins considérés.

- Pour X : $d(X, C) = 6$, $d(X, B) = 7$, $d(X, A) = 8$.

LOF : 1. Trouver les voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$D_k(x)$: distance au k-ième voisin. $N_k(x)$: ensemble des voisins considérés.

- Pour X : $d(X, C) = 6$, $d(X, B) = 7$, $d(X, A) = 8$.
- Donc $N_2(X) = \{C, B\}$ et $D_2(X) = 7$.

LOF : 1. Trouver les voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$D_k(x)$: distance au k-ième voisin. $N_k(x)$: ensemble des voisins considérés.

- Pour X : $d(X, C) = 6$, $d(X, B) = 7$, $d(X, A) = 8$.
- Donc $N_2(X) = \{C, B\}$ et $D_2(X) = 7$.

Point	Deux voisins	Distance au deuxième voisin
A	B, C	$D_2(A) = 2$
B	A, C	$D_2(B) = 1$
C	B, A	$D_2(C) = 2$

LOF : 2. Calculer les distances d'accessibilité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$R_k(x, y) = \max\{d(x, y), D_k(y)\}$$

LOF : 2. Calculer les distances d'accessibilité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$R_k(x, y) = \max\{d(x, y), D_k(y)\}$$

Pour X, les voisins sont C et B, avec $D_2(C) = 2$ et $D_2(B) = 1$.

LOF : 2. Calculer les distances d'accessibilité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$R_k(x, y) = \max\{d(x, y), D_k(y)\}$$

Pour X, les voisins sont C et B, avec $D_2(C) = 2$ et $D_2(B) = 1$.

$$R_2(X, C) = \max(6, 2) = 6$$

LOF : 2. Calculer les distances d'accessibilité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$R_k(x, y) = \max\{d(x, y), D_k(y)\}$$

Pour X, les voisins sont C et B, avec $D_2(C) = 2$ et $D_2(B) = 1$.

$$R_2(X, C) = \max(6, 2) = 6$$

$$R_2(X, B) = \max(7, 1) = 7$$

LOF : 2. Calculer les distances d'accessibilité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$R_k(x, y) = \max\{d(x, y), D_k(y)\}$$

Pour X, les voisins sont C et B, avec $D_2(C) = 2$ et $D_2(B) = 1$.

$$R_2(X, C) = \max(6, 2) = 6$$

$$R_2(X, B) = \max(7, 1) = 7$$

Le maximum évite qu'une distance très courte à un voisin produise une densité artificiellement élevée.

LOF : 3. De la distance moyenne à la densité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



Distance d'accessibilité moyenne

$$AR_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} R_k(x, y)$$

LOF : 3. De la distance moyenne à la densité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



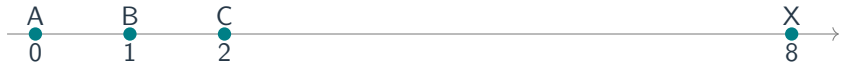
Distance d'accessibilité moyenne

$$AR_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} R_k(x, y)$$

$$AR_2(X) = \frac{6+7}{2} = 6{,}5$$

LOF : 3. De la distance moyenne à la densité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



Distance d'accessibilité moyenne

$$AR_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} R_k(x, y)$$

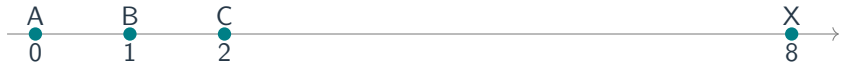
$$AR_2(X) = \frac{6+7}{2} = 6{,}5$$

Densité d'accessibilité locale

$$f_k(x) = \frac{1}{AR_k(x)}$$

LOF : 3. De la distance moyenne à la densité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



Distance d'accessibilité moyenne

$$AR_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} R_k(x, y)$$

$$AR_2(X) = \frac{6+7}{2} = 6{,}5$$

Densité d'accessibilité locale

$$f_k(x) = \frac{1}{AR_k(x)}$$

$$f_2(X) = \frac{1}{6{,}5} = \frac{2}{13} \simeq 0{,}154$$

LOF : 3. De la distance moyenne à la densité

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



Distance d'accessibilité moyenne

$$AR_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} R_k(x, y)$$

$$AR_2(X) = \frac{6+7}{2} = 6{,}5$$

Densité d'accessibilité locale

$$f_k(x) = \frac{1}{AR_k(x)}$$

$$f_2(X) = \frac{1}{6{,}5} = \frac{2}{13} \simeq 0{,}154$$

Des voisins éloignés donnent une grande distance moyenne, donc une faible densité locale.

LOF : 4. Calculer la densité des voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



On applique exactement les mêmes calculs aux voisins C et B de X.

LOF : 4. Calculer la densité des voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



On applique exactement les mêmes calculs aux voisins C et B de X.

Pour C : voisins B et A

$$R_2(C, B) = \max(1, 1) = 1$$

$$R_2(C, A) = \max(2, 2) = 2$$

$$f_2(C) = \frac{1}{(1+2)/2} = \frac{2}{3}$$

LOF : 4. Calculer la densité des voisins

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



On applique exactement les mêmes calculs aux voisins C et B de X.

Pour C : voisins B et A

$$R_2(C, B) = \max(1, 1) = 1$$

$$R_2(C, A) = \max(2, 2) = 2$$

$$f_2(C) = \frac{1}{(1+2)/2} = \frac{2}{3}$$

Pour B : voisins A et C

$$R_2(B, A) = \max(1, 2) = 2$$

$$R_2(B, C) = \max(1, 2) = 2$$

$$f_2(B) = \frac{1}{(2+2)/2} = \frac{1}{2}$$

LOF : 5. Comparer les densités

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$LOF_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} \frac{f_k(y)}{f_k(x)}$$

LOF : 5. Comparer les densités

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$LOF_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} \frac{f_k(y)}{f_k(x)}$$

$$LOF_2(X) = \frac{1}{2} \left(\frac{2/3}{2/13} + \frac{1/2}{2/13} \right)$$

LOF : 5. Comparer les densités

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$LOF_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} \frac{f_k(y)}{f_k(x)}$$

$$LOF_2(X) = \frac{1}{2}\left(\frac{2/3}{2/13} + \frac{1/2}{2/13}\right)$$

$$= \frac{1}{2}\left(\frac{13}{3} + \frac{13}{4}\right) = \frac{91}{24} \simeq \boxed{3{,}79}$$

LOF : 5. Comparer les densités

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



$$LOF_k(x) = \frac{1}{|N_k(x)|} \sum_{y \in N_k(x)} \frac{f_k(y)}{f_k(x)}$$

$$LOF_2(X) = \frac{1}{2}\left(\frac{2/3}{2/13} + \frac{1/2}{2/13}\right)$$

$$= \frac{1}{2}\left(\frac{13}{3} + \frac{13}{4}\right) = \frac{91}{24} \simeq \boxed{3{,}79}$$

La densité moyenne des voisins vaut environ **3,79 fois** celle de X. Son score signale un isolement local marqué.

LOF : 6. Interpréter le score

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



- $LOF \simeq 1$: densité comparable à celle des voisins.

LOF : 6. Interpréter le score

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



- $LOF \simeq 1$: densité comparable à celle des voisins.
- $LOF < 1$: densité locale supérieure à celle des voisins.

LOF : 6. Interpréter le score

Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



- $LOF \simeq 1$: densité comparable à celle des voisins.
- $LOF < 1$: densité locale supérieure à celle des voisins.
- $LOF \gg 1$: densité beaucoup plus faible que celle des voisins.

LOF : 6. Interpréter le score

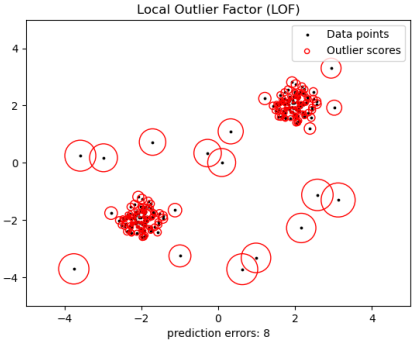
Même exemple : $k = 2$, $A = 0$, $B = 1$, $C = 2$, $X = 8$.



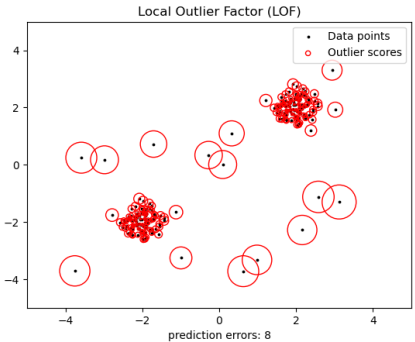
- $LOF \simeq 1$: densité comparable à celle des voisins.
- $LOF < 1$: densité locale supérieure à celle des voisins.
- $LOF \gg 1$: densité beaucoup plus faible que celle des voisins.

Ici, $LOF_2(X) \simeq 3{,}79$: X est un candidat anomalie. Le score sert à classer les observations, puis à choisir celles à signaler.

Local Outlier Factor : détection d'outliers

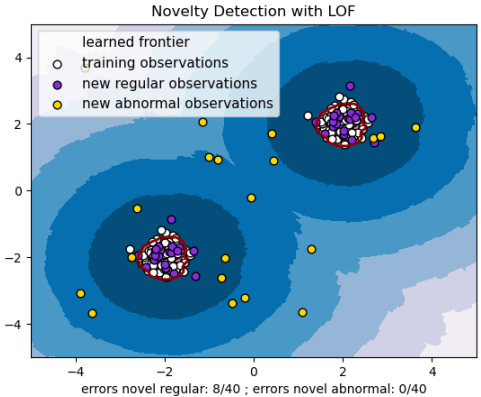


Local Outlier Factor : détection d'outliers



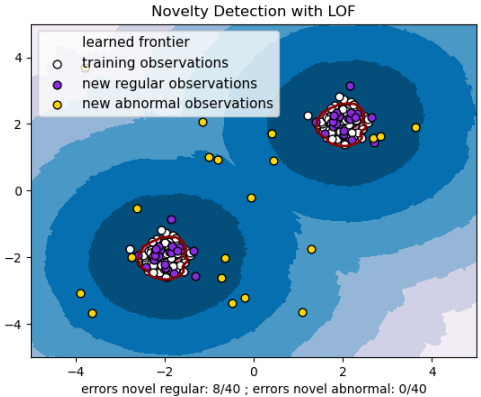
LOF s'utilise pour la détection d'outliers ou de nouveautés. Il est adapté à des données de dimension modérée.

Local Outlier Factor : détection de nouveautés



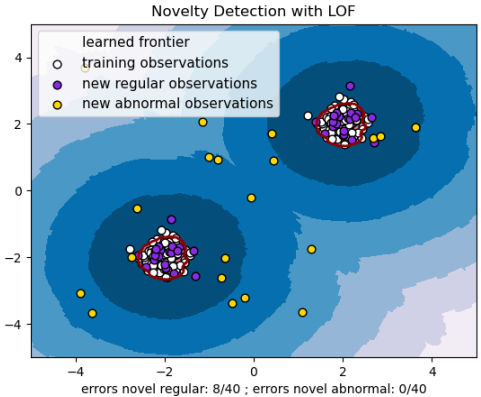
- Observations d'apprentissage.

Local Outlier Factor : détection de nouveautés



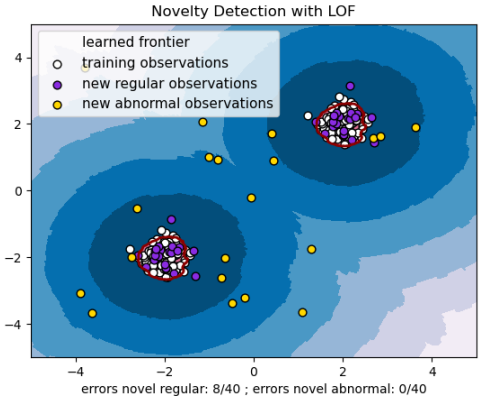
- Observations d'apprentissage.
- Frontière apprise.

Local Outlier Factor : détection de nouveautés



- Observations d'apprentissage.
- Frontière apprise.
- Nouvelles observations normales.

Local Outlier Factor : détection de nouveautés



- Observations d'apprentissage.
- Frontière apprise.
- Nouvelles observations normales.
- Nouvelles observations atypiques.

Autres approches non supervisées

PCA : analyse en composantes principales

La PCA résume les variations habituelles avec quelques axes, puis signale les observations qu'elle reconstruit mal à partir de ces axes.

Autres approches non supervisées

PCA : analyse en composantes principales

La PCA résume les variations habituelles avec quelques axes, puis signale les observations qu'elle reconstruit mal à partir de ces axes.

One-Class SVM

Le modèle apprend une frontière autour de la région occupée par les observations normales et considère les nouveaux points situés à l'extérieur comme potentiellement anormaux.

Autres approches non supervisées

PCA : analyse en composantes principales

La PCA résume les variations habituelles avec quelques axes, puis signale les observations qu'elle reconstruit mal à partir de ces axes.

One-Class SVM

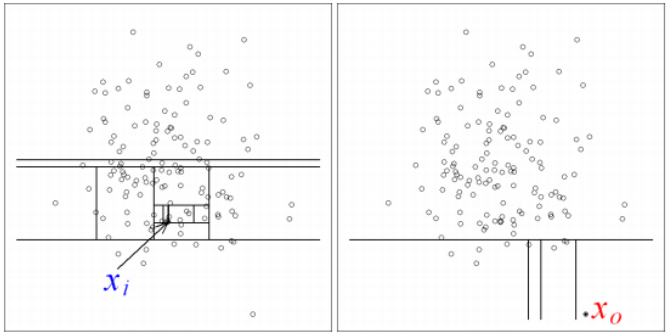
Le modèle apprend une frontière autour de la région occupée par les observations normales et considère les nouveaux points situés à l'extérieur comme potentiellement anormaux.

Isolation Forest

Des coupures aléatoires isolent plus rapidement certaines observations atypiques.

Isolation Forest : le principe

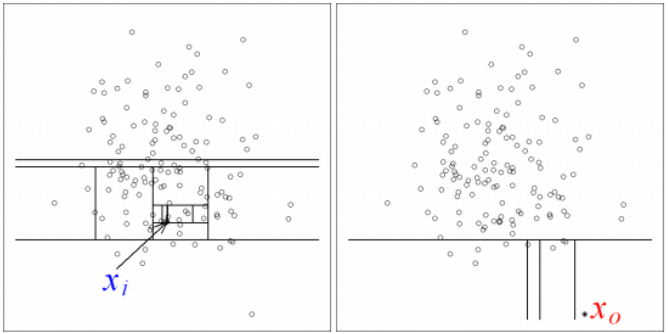
Les anomalies sont rares et différentes. Elles sont donc susceptibles d'être isolées rapidement.



(a) Isolating x_i (b) Isolating x_o

Isolation Forest : le principe

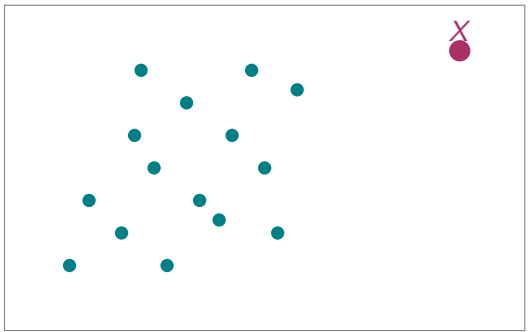
Les anomalies sont rares et différentes. Elles sont donc susceptibles d'être isolées rapidement.



(a) Isolating x_i (b) Isolating x_o

Point dans le nuage : davantage de coupures. Point isolé : moins de coupures.

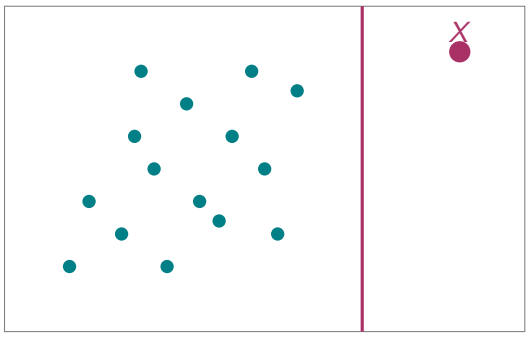
Isolation Forest : isoler un point pas à pas



1. Nuage de points et observation isolée X.

Exemple illustratif d'un arbre. Les coupures changent d'un arbre à l'autre.

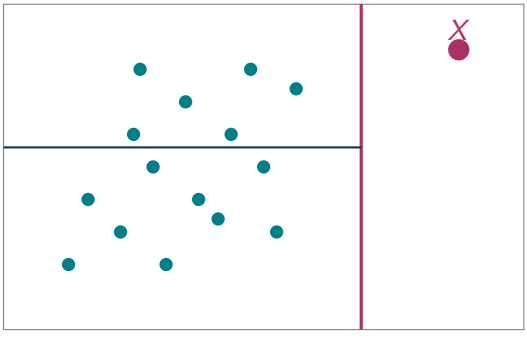
Isolation Forest : isoler un point pas à pas



1. Nuage de points et observation isolée X.
2. Une coupure aléatoire isole X : chemin de longueur 1.

Exemple illustratif d'un arbre. Les coupures changent d'un arbre à l'autre.

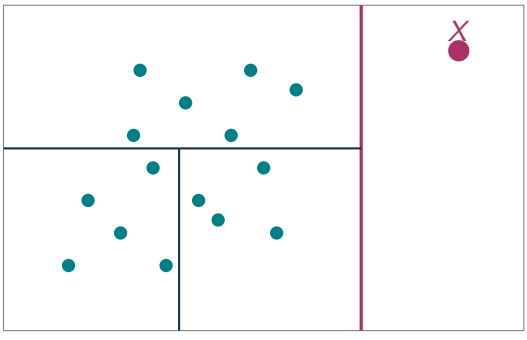
Isolation Forest : isoler un point pas à pas



1. Nuage de points et observation isolée X.
2. Une coupure aléatoire isole X : chemin de longueur 1.
3. Les points du nuage restent regroupés.

Exemple illustratif d'un arbre. Les coupures changent d'un arbre à l'autre.

Isolation Forest : isoler un point pas à pas

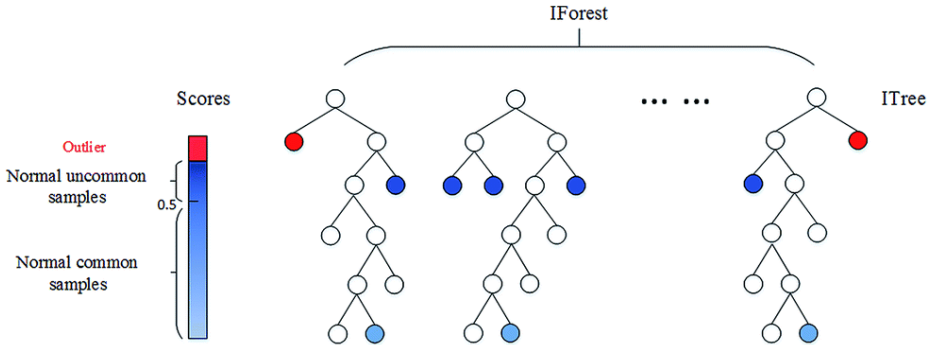


1. Nuage de points et observation isolée X.
2. Une coupure aléatoire isole X : chemin de longueur 1.
3. Les points du nuage restent regroupés.
4. D'autres coupures sont nécessaires pour les isoler.

Exemple illustratif d'un arbre. Les coupures changent d'un arbre à l'autre.

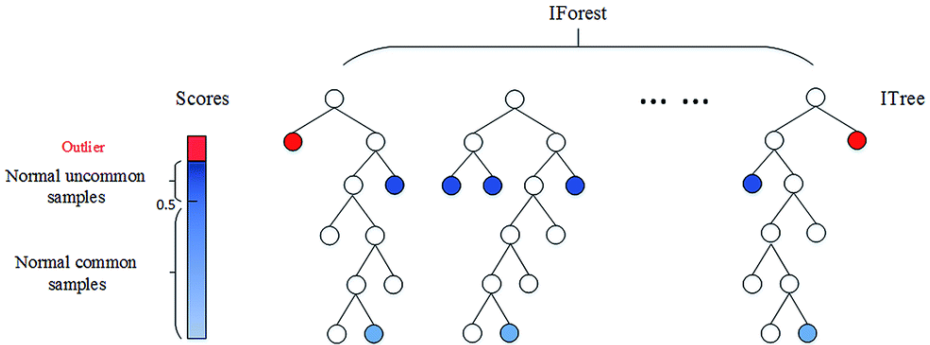
Isolation Forest : de l'arbre à la forêt

Les anomalies sont rares et différentes : elles tendent à avoir des chemins plus courts.



Isolation Forest : de l'arbre à la forêt

Les anomalies sont rares et différentes : elles tendent à avoir des chemins plus courts.



Agréger les longueurs de chemin obtenues dans plusieurs arbres.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.
- À chaque nœud, tirer une variable numérique au hasard, puis un seuil entre son minimum et son maximum dans ce nœud.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.
- À chaque nœud, tirer une variable numérique au hasard, puis un seuil entre son minimum et son maximum dans ce nœud.
- Répartir les observations dans les deux enfants et recommencer.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.
- À chaque nœud, tirer une variable numérique au hasard, puis un seuil entre son minimum et son maximum dans ce nœud.
- Répartir les observations dans les deux enfants et recommencer.
- Arrêter si une seule observation reste, si aucune séparation n'est possible, ou si la profondeur limite est atteinte.

Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.
- À chaque nœud, tirer une variable numérique au hasard, puis un seuil entre son minimum et son maximum dans ce nœud.
- Répartir les observations dans les deux enfants et recommencer.
- Arrêter si une seule observation reste, si aucune séparation n'est possible, ou si la profondeur limite est atteinte.

La profondeur limite usuelle est $\lceil \log_2 \psi \rceil$. Une feuille peut donc contenir plusieurs observations.

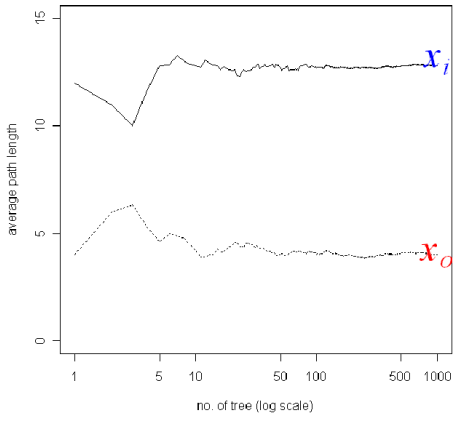
Isolation Forest : construction des arbres

- Construire chaque arbre sur un sous-échantillon de ψ observations.
- Dans scikit-learn, `max_samples='auto'` donne $\psi = \min(256, N)$, où N est la taille de l'apprentissage. On peut choisir une valeur supérieure à 256 avec `max_samples`.
- À chaque nœud, tirer une variable numérique au hasard, puis un seuil entre son minimum et son maximum dans ce nœud.
- Répartir les observations dans les deux enfants et recommencer.
- Arrêter si une seule observation reste, si aucune séparation n'est possible, ou si la profondeur limite est atteinte.

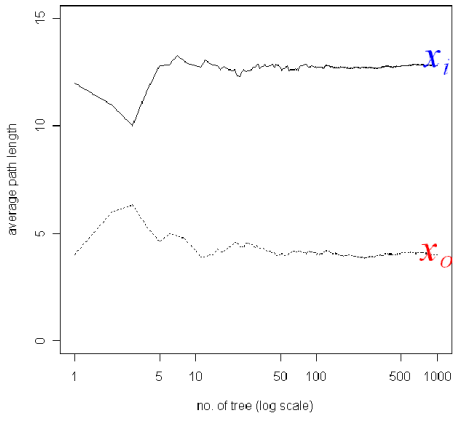
La profondeur limite usuelle est $\lceil \log_2 \psi \rceil$. Une feuille peut donc contenir plusieurs observations.

Exemple : $\psi = 8$ donne une profondeur limite de 3 coupures.

Isolation Forest : convergence

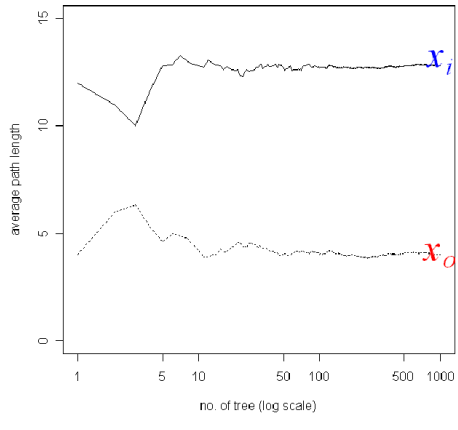


Isolation Forest : convergence



Convergence rapide

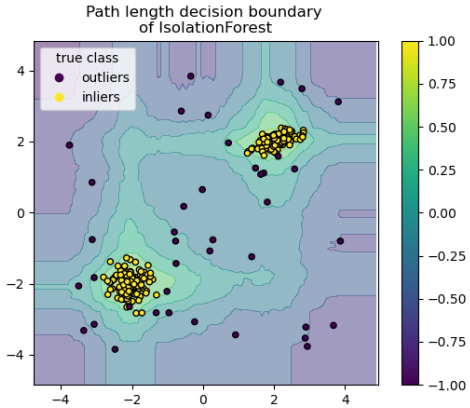
Isolation Forest : convergence



Convergence rapide
Les longueurs

moyennes se stabilisent lorsque le nombre d'arbres augmente.

Isolation Forest : frontière de décision



Isolation Forest : une ou plusieurs observations par feuille ?

Feuille contenant une observation

Le point est isolé.

La longueur $h(x)$ est le nombre de coupures parcourues depuis la racine.

Isolation Forest : une ou plusieurs observations par feuille ?

Feuille contenant une observation

Le point est isolé.

La longueur $h(x)$ est le nombre de coupures parcourues depuis la racine.

Exemple : isolé après 2 coupures, donc $h(x) = 2$.

Isolation Forest : une ou plusieurs observations par feuille ?

Feuille contenant une observation

Le point est isolé.

La longueur $h(x)$ est le nombre de coupures parcourues depuis la racine.

Exemple : isolé après 2 coupures, donc $h(x) = 2$.

Feuille contenant $m > 1$ observations

L'arbre s'est arrêté avant l'isolation complète.

On ajoute une estimation $c(m)$ du nombre de coupures encore nécessaires.

Isolation Forest : une ou plusieurs observations par feuille ?

Feuille contenant une observation

Le point est isolé.

La longueur $h(x)$ est le nombre de coupures parcourues depuis la racine.

Exemple : isolé après 2 coupures, donc $h(x) = 2$.

Feuille contenant $m > 1$ observations

L'arbre s'est arrêté avant l'isolation complète.

On ajoute une estimation $c(m)$ du nombre de coupures encore nécessaires.

$$h(x) = d + c(m)$$

Isolation Forest : une ou plusieurs observations par feuille ?

Feuille contenant une observation

Le point est isolé.

La longueur $h(x)$ est le nombre de coupures parcourues depuis la racine.

Exemple : isolé après 2 coupures, donc $h(x) = 2$.

Feuille contenant $m > 1$ observations

L'arbre s'est arrêté avant l'isolation complète.

On ajoute une estimation $c(m)$ du nombre de coupures encore nécessaires.

$$h(x) = d + c(m)$$

Si $d = 3$ et $m = 2$, il manque une coupure : $c(2) = 1$, donc $h(x) = 4$. On ne construit pas réellement cette coupure supplémentaire.

Isolation Forest : calculer le score original d'anomalie

Pour T arbres, on moyenne les longueurs de chemin, corrigées si nécessaire :

$$\overline{h}(x) = \frac{1}{T} \sum_{t=1}^{T} h_t(x).$$

Isolation Forest : calculer le score original d'anomalie

Pour T arbres, on moyenne les longueurs de chemin, corrigées si nécessaire :

$$\overline{h}(x) = \frac{1}{T} \sum_{t=1}^{T} h_t(x).$$

$$\boxed{s(x) = 2^{-\overline{h}(x)/c(\psi)}}$$

Isolation Forest : calculer le score original d'anomalie

Pour T arbres, on moyenne les longueurs de chemin, corrigées si nécessaire :

$$\overline{h}(x) = \frac{1}{T} \sum_{t=1}^{T} h_t(x).$$

$$\boxed{s(x) = 2^{-\overline{h}(x)/c(\psi)}}$$

- $c(\psi)$ est une longueur de référence liée à la taille du sous-échantillon.
- Score original : chemin moyen court, score proche de 1, observation plus atypique.
- $\overline{h}(x) = c(\psi)$ donne $s(x) = 0{,}5$.

Isolation Forest : calculer le score original d'anomalie

Pour T arbres, on moyenne les longueurs de chemin, corrigées si nécessaire :

$$\overline{h}(x) = \frac{1}{T} \sum_{t=1}^{T} h_t(x).$$

$$\boxed{s(x) = 2^{-\overline{h}(x)/c(\psi)}}$$

- $c(\psi)$ est une longueur de référence liée à la taille du sous-échantillon.
- Score original : chemin moyen court, score proche de 1, observation plus atypique.
- $\overline{h}(x) = c(\psi)$ donne $s(x) = 0{,}5$.

Pour calculer la référence : $c(n) = 2H_{n-1} - 2(n-1)/n$, où $H_j = \sum_{i=1}^{j} 1/i$, pour $n \geq 2$ et $c(1) = 0$. Ici, $c(8) \simeq 3{,}436$.

Isolation Forest : calculer le score original d'anomalie

Pour T arbres, on moyenne les longueurs de chemin, corrigées si nécessaire :

$$\overline{h}(x) = \frac{1}{T} \sum_{t=1}^{T} h_t(x).$$

$$\boxed{s(x) = 2^{-\overline{h}(x)/c(\psi)}}$$

- $c(\psi)$ est une longueur de référence liée à la taille du sous-échantillon.
- Score original : chemin moyen court, score proche de 1, observation plus atypique.
- $\overline{h}(x) = c(\psi)$ donne $s(x) = 0{,}5$.

Pour calculer la référence : $c(n) = 2H_{n-1} - 2(n-1)/n$, où $H_j = \sum_{i=1}^{j} 1/i$, pour $n \geq 2$ et $c(1) = 0$. Ici, $c(8) \simeq 3{,}436$.

Ce score n'est pas une probabilité d'anomalie. Le seuil d'alerte reste à choisir.

Isolation Forest : exemple de score sur trois arbres

Sous-échantillons de taille $\psi = 8$. Longueur de référence $c(8) \simeq 3{,}436$.

Observation	Arbre 1	Arbre 2	Arbre 3
X, facilement isolée	1	2	2
Z, dans le nuage	4	4	4

Les valeurs 4 peuvent correspondre à $d = 3$ et à une feuille de 2 observations.

Isolation Forest : exemple de score sur trois arbres

Sous-échantillons de taille $\psi = 8$. Longueur de référence $c(8) \simeq 3{,}436$.

Observation	Arbre 1	Arbre 2	Arbre 3
X, facilement isolée	1	2	2
Z, dans le nuage	4	4	4

Les valeurs 4 peuvent correspondre à $d = 3$ et à une feuille de 2 observations.

$$\overline{h}(X) = \frac{1+2+2}{3} = \frac{5}{3}, \qquad \overline{h}(Z) = 4$$

Isolation Forest : exemple de score sur trois arbres

Sous-échantillons de taille $\psi = 8$. Longueur de référence $c(8) \simeq 3{,}436$.

Observation	Arbre 1	Arbre 2	Arbre 3
X, facilement isolée	1	2	2
Z, dans le nuage	4	4	4

Les valeurs 4 peuvent correspondre à $d = 3$ et à une feuille de 2 observations.

$$\overline{h}(X) = \frac{1+2+2}{3} = \frac{5}{3}, \qquad \overline{h}(Z) = 4$$

$$s(X) = 2^{-(5/3)/3{,}436} \simeq 0{,}714, \qquad s(Z) = 2^{-4/3{,}436} \simeq 0{,}446$$

Isolation Forest : exemple de score sur trois arbres

Sous-échantillons de taille $\psi = 8$. Longueur de référence $c(8) \simeq 3{,}436$.

Observation	Arbre 1	Arbre 2	Arbre 3
X, facilement isolée	1	2	2
Z, dans le nuage	4	4	4

Les valeurs 4 peuvent correspondre à $d = 3$ et à une feuille de 2 observations.

$$\overline{h}(X) = \frac{1+2+2}{3} = \frac{5}{3}, \qquad \overline{h}(Z) = 4$$

$$s(X) = 2^{-(5/3)/3{,}436} \simeq 0{,}714, \qquad s(Z) = 2^{-4/3{,}436} \simeq 0{,}446$$

Score original : X a le score le plus élevé, car ses chemins sont plus courts.

Isolation Forest : exemple de score sur trois arbres

Sous-échantillons de taille $\psi = 8$. Longueur de référence $c(8) \simeq 3{,}436$.

Observation	Arbre 1	Arbre 2	Arbre 3
X, facilement isolée	1	2	2
Z, dans le nuage	4	4	4

Les valeurs 4 peuvent correspondre à $d = 3$ et à une feuille de 2 observations.

$$\overline{h}(X) = \frac{1+2+2}{3} = \frac{5}{3}, \qquad \overline{h}(Z) = 4$$

$$s(X) = 2^{-(5/3)/3{,}436} \simeq 0{,}714, \qquad s(Z) = 2^{-4/3{,}436} \simeq 0{,}446$$

Score original : X a le score le plus élevé, car ses chemins sont plus courts.

Dans scikit-learn : plus faible = plus atypique

`score_samples` utilise le signe opposé au score original.
`decision_function = score_samples - offset_` : anomalie si le résultat est < 0.

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.
- Une perte donnant le même poids à chaque observation peut conduire le modèle à privilégier la classe majoritaire.

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.
- Une perte donnant le même poids à chaque observation peut conduire le modèle à privilégier la classe majoritaire.
- Adapter les approches supervisées existantes :

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.
- Une perte donnant le même poids à chaque observation peut conduire le modèle à privilégier la classe majoritaire.
- Adapter les approches supervisées existantes :
  - **Under-sampling** : sous-échantillonnage, avec `imbalanced-learn`.

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.
- Une perte donnant le même poids à chaque observation peut conduire le modèle à privilégier la classe majoritaire.
- Adapter les approches supervisées existantes :
  - **Under-sampling** : sous-échantillonnage, avec `imbalanced-learn`.
  - **Over-sampling** : suréchantillonnage, avec `imbalanced-learn`.

Apprendre sur des données déséquilibrées

- Exemple : 95 % d'observations normales et 5 % d'anomalies.
- Une perte donnant le même poids à chaque observation peut conduire le modèle à privilégier la classe majoritaire.
- Adapter les approches supervisées existantes :
  - **Under-sampling** : sous-échantillonnage, avec `imbalanced-learn`.
  - **Over-sampling** : suréchantillonnage, avec `imbalanced-learn`.
  - **Pondération des classes** : notamment avec `scikit-learn`.

Sous-échantillonnage et suréchantillonnage

Random under-sampling

Supprimer aléatoirement une partie des observations de la classe majoritaire.

Sous-échantillonnage et suréchantillonnage

Random under-sampling

Supprimer aléatoirement une partie des observations de la classe majoritaire.

Random over-sampling

Dupliquer aléatoirement des observations de la classe minoritaire.

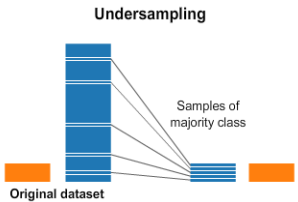
Sous-échantillonnage et suréchantillonnage

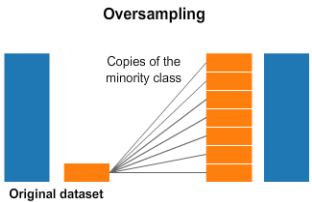
Random under-sampling

Supprimer aléatoirement une partie des observations de la classe majoritaire.

Random over-sampling

Dupliquer aléatoirement des observations de la classe minoritaire.





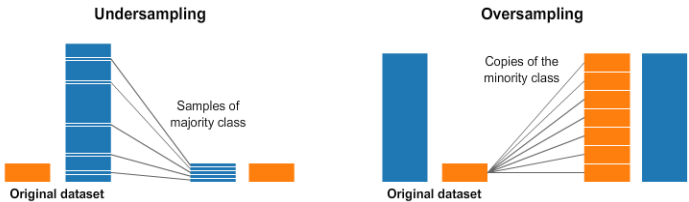
Sous-échantillonnage et suréchantillonnage

Random under-sampling

Supprimer aléatoirement une partie des observations de la classe majoritaire.

Random over-sampling

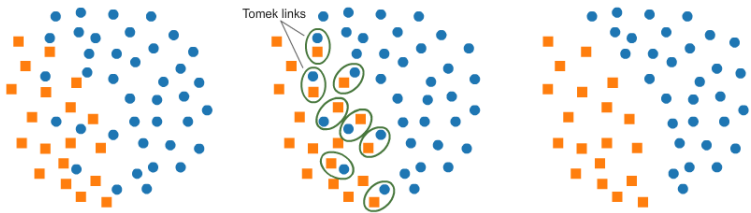
Dupliquer aléatoirement des observations de la classe minoritaire.



Ces opérations modifient uniquement les données d'apprentissage.

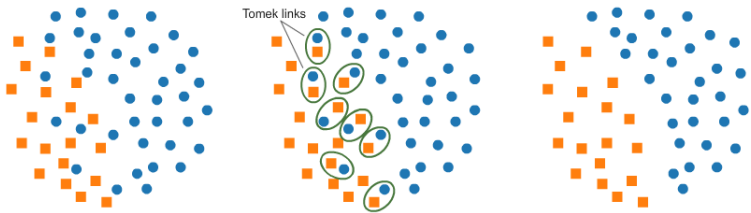
Tomek Links : nettoyer la frontière entre les classes

- Deux observations de classes différentes forment un lien de Tomek si chacune est le plus proche voisin de l'autre (sans ex æquo ici).



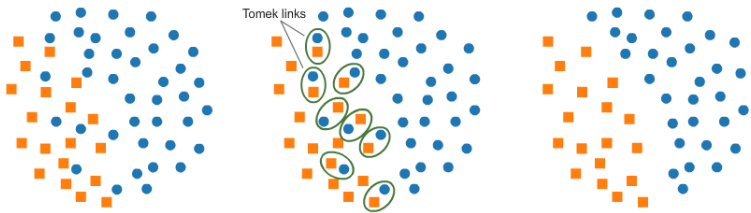
Tomek Links : nettoyer la frontière entre les classes

- Deux observations de classes différentes forment un lien de Tomek si chacune est le plus proche voisin de l'autre (sans ex æquo ici).
- Pour sous-échantillonner la classe majoritaire, on retire le membre majoritaire de chaque paire sélectionnée.



Tomek Links : nettoyer la frontière entre les classes

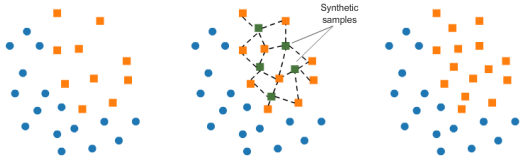
- Deux observations de classes différentes forment un lien de Tomek si chacune est le plus proche voisin de l'autre (sans ex æquo ici).
- Pour sous-échantillonner la classe majoritaire, on retire le membre majoritaire de chaque paire sélectionnée.



Appliquer ce nettoyage uniquement à l'apprentissage. Les données de validation et de test conservent leur distribution réelle.

SMOTE : créer des observations minoritaires

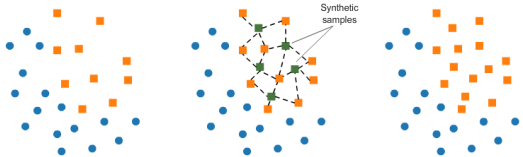
Synthetic Minority Oversampling Technique



1. Sélectionner une observation minoritaire initiale x.

SMOTE : créer des observations minoritaires

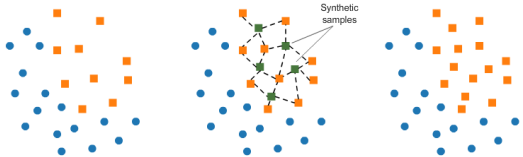
Synthetic Minority Oversampling Technique



1. Sélectionner une observation minoritaire initiale x.
2. Identifier ses k plus proches voisins minoritaires.

SMOTE : créer des observations minoritaires

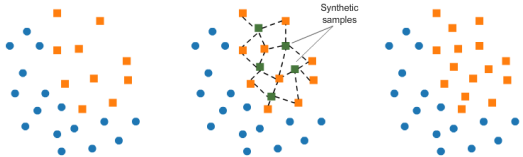
Synthetic Minority Oversampling Technique



1. Sélectionner une observation minoritaire initiale x.
2. Identifier ses k plus proches voisins minoritaires.
3. Tirer au hasard l'un de ces voisins, x_v.

SMOTE : créer des observations minoritaires

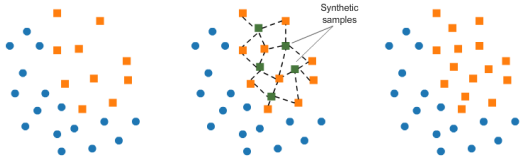
Synthetic Minority Oversampling Technique



1. Sélectionner une observation minoritaire initiale x.
2. Identifier ses k plus proches voisins minoritaires.
3. Tirer au hasard l'un de ces voisins, x_v.
4. Tirer un coefficient $\alpha \in [0, 1]$.

SMOTE : créer des observations minoritaires

Synthetic Minority Oversampling Technique

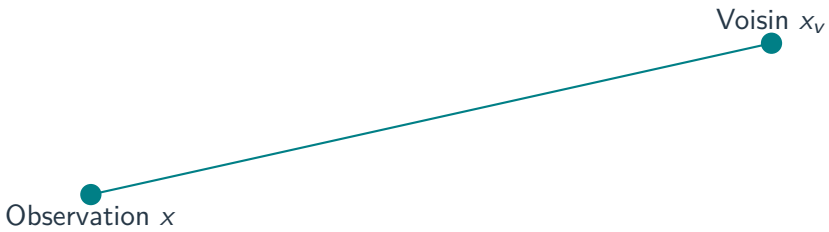


1. Sélectionner une observation minoritaire initiale x.
2. Identifier ses k plus proches voisins minoritaires.
3. Tirer au hasard l'un de ces voisins, x_v.
4. Tirer un coefficient $\alpha \in [0, 1]$.
5. Créer un individu entre x et x_v : $x_{\text{nouveau}} = x + \alpha(x_v - x)$.

SMOTE : une interpolation progressive

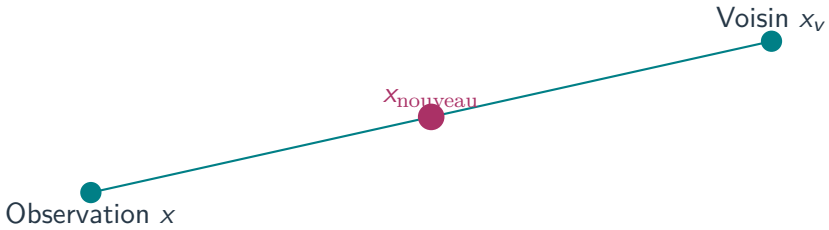


SMOTE : une interpolation progressive



$$x_{\text{nouveau}} = x + \alpha(x_v - x)$$

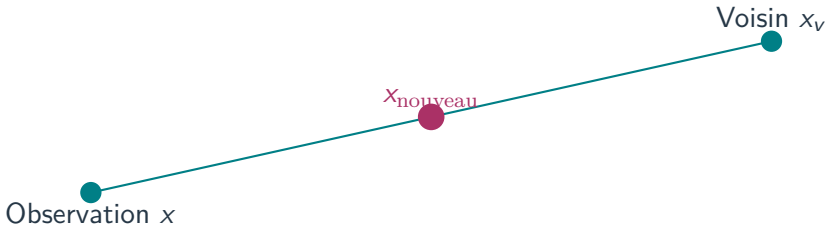
SMOTE : une interpolation progressive



$$x_{\text{nouveau}} = x + \alpha(x_v - x)$$

$$\alpha = 0{,}5 \quad \Longrightarrow \quad x_{\text{nouveau}} = \frac{x + x_v}{2}$$

SMOTE : une interpolation progressive



$$x_{\text{nouveau}} = x + \alpha(x_v - x)$$

$$\alpha = 0{,}5 \quad \Longrightarrow \quad x_{\text{nouveau}} = \frac{x + x_v}{2}$$

Le nouvel individu se trouve à mi-chemin entre les deux observations minoritaires.

SMOTE et Tomek Links : à quel moment les appliquer ?

1. Séparer les données en apprentissage, validation et test.

SMOTE et Tomek Links : à quel moment les appliquer ?

1. Séparer les données en apprentissage, validation et test.
2. Appliquer SMOTE, Tomek Links ou un autre rééchantillonnage à **l'apprentissage seulement**.

SMOTE et Tomek Links : à quel moment les appliquer ?

1. Séparer les données en apprentissage, validation et test.
2. Appliquer SMOTE, Tomek Links ou un autre rééchantillonnage à **l'apprentissage seulement**.
3. Apprendre le modèle sur les données obtenues.

SMOTE et Tomek Links : à quel moment les appliquer ?

1. Séparer les données en apprentissage, validation et test.
2. Appliquer SMOTE, Tomek Links ou un autre rééchantillonnage à **l'apprentissage seulement**.
3. Apprendre le modèle sur les données obtenues.
4. Choisir le seuil sur validation et mesurer la performance finale sur test, sans les rééquilibrer.

SMOTE et Tomek Links : à quel moment les appliquer ?

1. Séparer les données en apprentissage, validation et test.
2. Appliquer SMOTE, Tomek Links ou un autre rééchantillonnage à **l'apprentissage seulement**.
3. Apprendre le modèle sur les données obtenues.
4. Choisir le seuil sur validation et mesurer la performance finale sur test, sans les rééquilibrer.

La validation croisée est facultative. Si elle est utilisée, refaire le rééchantillonnage uniquement dans la partie apprentissage de chaque pli.

Pondération des classes : modifier la perte

- Pénaliser davantage les erreurs sur la classe minoritaire, sans modifier les observations.

Pondération des classes : modifier la perte

- Pénaliser davantage les erreurs sur la classe minoritaire, sans modifier les observations.
- Plusieurs modèles proposent l'argument `class_weight` : régression logistique, SVM, forêts aléatoires, etc.

Pondération des classes : modifier la perte

- Pénaliser davantage les erreurs sur la classe minoritaire, sans modifier les observations.
- Plusieurs modèles proposent l'argument `class_weight` : régression logistique, SVM, forêts aléatoires, etc.

```
LogisticRegression(class_weight={0:1, 1:20})
```

Pondération des classes : modifier la perte

- Pénaliser davantage les erreurs sur la classe minoritaire, sans modifier les observations.
- Plusieurs modèles proposent l'argument `class_weight` : régression logistique, SVM, forêts aléatoires, etc.

```
LogisticRegression(class_weight={0:1, 1:20})
```

$$L(y, p) = -y \log(p) - (1 - y) \log(1 - p)$$

Pondération des classes : modifier la perte

- Pénaliser davantage les erreurs sur la classe minoritaire, sans modifier les observations.
- Plusieurs modèles proposent l'argument `class_weight` : régression logistique, SVM, forêts aléatoires, etc.

```
LogisticRegression(class_weight={0:1, 1:20})
```

$$L(y, p) = -y \log(p) - (1 - y) \log(1 - p)$$

$$L_w(y, p) = -20y \log(p) - (1 - y) \log(1 - p)$$

$y = 1$ pour une anomalie. p désigne la probabilité prédite.

Pondération des classes : exemple numérique

Avec les poids $w_0 = 1$ et $w_1 = 20$, le terme de perte d'un positif reçoit un poids 20 fois supérieur.

Observation positive : $y = 1$, $p = 0{,}3$

Observation négative : $y = 0$, $p = 0{,}7$

Pondération des classes : exemple numérique

Avec les poids $w_0 = 1$ et $w_1 = 20$, le terme de perte d'un positif reçoit un poids 20 fois supérieur.

Observation positive : $y = 1$, $p = 0{,}3$

$$L_w = -20 \log_{10}(0{,}3) \simeq 10{,}46$$

Observation négative : $y = 0$, $p = 0{,}7$

Pondération des classes : exemple numérique

Avec les poids $w_0 = 1$ et $w_1 = 20$, le terme de perte d'un positif reçoit un poids 20 fois supérieur.

Observation positive : $y = 1$, $p = 0{,}3$

$$L_w = -20 \log_{10}(0{,}3) \simeq 10{,}46$$

Observation négative : $y = 0$, $p = 0{,}7$

$$L_w = -\log_{10}(1 - 0{,}7) = -\log_{10}(0{,}3) \simeq 0{,}52$$

Pondération des classes : exemple numérique

Avec les poids $w_0 = 1$ et $w_1 = 20$, le terme de perte d'un positif reçoit un poids 20 fois supérieur.

Observation positive : $y = 1$, $p = 0{,}3$

$$L_w = -20 \log_{10}(0{,}3) \simeq 10{,}46$$

Observation négative : $y = 0$, $p = 0{,}7$

$$L_w = -\log_{10}(1 - 0{,}7) = -\log_{10}(0{,}3) \simeq 0{,}52$$

Même probabilité affectée à la vraie classe, mais une contribution à la perte multipliée par 20.

Comment calculer les poids des classes ?

$$w_i = \frac{N}{K\, n_i}$$

- N : nombre total d'exemples.
- K : nombre de classes.
- n_i : nombre d'exemples de la classe i.

Comment calculer les poids des classes ?

$$w_i = \frac{N}{K\, n_i}$$

- N : nombre total d'exemples.
- K : nombre de classes.
- n_i : nombre d'exemples de la classe i.

Exemple : 90 observations normales et 10 anomalies.

Comment calculer les poids des classes ?

$$w_i = \frac{N}{K\, n_i}$$

- N : nombre total d'exemples.
- K : nombre de classes.
- n_i : nombre d'exemples de la classe i.

Exemple : 90 observations normales et 10 anomalies.

$$w_0 = \frac{100}{2 \times 90} \simeq 0{,}56$$

Comment calculer les poids des classes ?

$$w_i = \frac{N}{K\, n_i}$$

- N : nombre total d'exemples.
- K : nombre de classes.
- n_i : nombre d'exemples de la classe i.

Exemple : 90 observations normales et 10 anomalies.

$$w_0 = \frac{100}{2 \times 90} \simeq 0{,}56 \qquad w_1 = \frac{100}{2 \times 10} = 5$$

Évaluation : bien choisir la métrique

- L'accuracy peut être trompeuse sur des classes déséquilibrées.

Évaluation : bien choisir la métrique

- L'accuracy peut être trompeuse sur des classes déséquilibrées.
- Pour évaluer les **classes prédites** (0/1) :

Évaluation : bien choisir la métrique

- L'accuracy peut être trompeuse sur des classes déséquilibrées.
- Pour évaluer les **classes prédites** $(0/1)$:
  - **Balanced accuracy** : accorder autant d'importance au rappel de chaque classe.

$$\text{Balanced accuracy} = \frac{\text{Rappel}_+ + \text{Rappel}_-}{2}$$

Évaluation : bien choisir la métrique

- L'accuracy peut être trompeuse sur des classes déséquilibrées.
- Pour évaluer les **classes prédites** $(0/1)$:
  - **Balanced accuracy** : accorder autant d'importance au rappel de chaque classe.
  - **F1-score** : porter l'attention sur la classe positive, à travers sa précision et son rappel.

$$\text{Balanced accuracy} = \frac{\text{Rappel}_+ + \text{Rappel}_-}{2}$$

$$F_1 = \frac{2 \times \text{Précision}_+ \times \text{Rappel}_+}{\text{Précision}_+ + \text{Rappel}_+}$$

Trois classifieurs sur les mêmes données

999 900 observations normales et 100 anomalies.

	Classifieur naïf	Mauvais classifieur	Bon classifieur
Vrais négatifs	999 900	997 990	999 890
Faux positifs	0	1 910	10
Faux négatifs	100	10	10
Vrais positifs	0	90	90

* Convention : précision fixée à 0 en l'absence de prédictions positives.

Trois classifieurs sur les mêmes données

999 900 observations normales et 100 anomalies.

	Classifieur naïf	Mauvais classifieur	Bon classifieur
Vrais négatifs	999 900	997 990	999 890
Faux positifs	0	1 910	10
Faux négatifs	100	10	10
Vrais positifs	0	90	90
Accuracy	0,999900	0,998080	0,999980

* Convention : précision fixée à 0 en l'absence de prédictions positives.

Trois classifieurs sur les mêmes données

999 900 observations normales et 100 anomalies.

	Classifieur naïf	Mauvais classifieur	Bon classifieur
Vrais négatifs	999 900	997 990	999 890
Faux positifs	0	1 910	10
Faux négatifs	100	10	10
Vrais positifs	0	90	90
Accuracy	0,999900	0,998080	0,999980
Précision +	0*	0,045	0,900
Rappel +	0	0,900	0,900

* Convention : précision fixée à 0 en l'absence de prédictions positives.

Trois classifieurs sur les mêmes données

999 900 observations normales et 100 anomalies.

	Classifieur naïf	Mauvais classifieur	Bon classifieur
Vrais négatifs	999 900	997 990	999 890
Faux positifs	0	1 910	10
Faux négatifs	100	10	10
Vrais positifs	0	90	90
Accuracy	0,999900	0,998080	0,999980
Précision +	0*	0,045	0,900
Rappel +	0	0,900	0,900
Rappel –	1	0,998090	0,999990
Balanced accuracy	0,500	0,949045	0,949995

* Convention : précision fixée à 0 en l'absence de prédictions positives.

Trois classifieurs sur les mêmes données

999 900 observations normales et 100 anomalies.

	Classifieur naïf	Mauvais classifieur	Bon classifieur
Vrais négatifs	999 900	997 990	999 890
Faux positifs	0	1 910	10
Faux négatifs	100	10	10
Vrais positifs	0	90	90
Accuracy	0,999900	0,998080	0,999980
Précision +	0*	0,045	0,900
Rappel +	0	0,900	0,900
Rappel –	1	0,998090	0,999990
Balanced accuracy	0,500	0,949045	0,949995
F1-score	0	0,085714	0,900

* Convention : précision fixée à 0 en l'absence de prédictions positives.

Si vous vous intéressez aux probabilités prédites

- Utiliser les probabilités $p(Y = 1 \mid x)$ ou, plus généralement, les **scores continus** du modèle.

Si vous vous intéressez aux probabilités prédites

- Utiliser les probabilités $p(Y = 1 \mid x)$ ou, plus généralement, les **scores continus** du modèle.
- Faire varier le seuil pour observer les compromis possibles.

Si vous vous intéressez aux probabilités prédites

- Utiliser les probabilités $p(Y = 1 \mid x)$ ou, plus généralement, les **scores continus** du modèle.
- Faire varier le seuil pour observer les compromis possibles.
- **ROC-AUC** : étudier le classement relatif des positifs et des négatifs, via les taux TPR et FPR.

Si vous vous intéressez aux probabilités prédites

- Utiliser les probabilités $p(Y = 1 \mid x)$ ou, plus généralement, les **scores continus** du modèle.
- Faire varier le seuil pour observer les compromis possibles.
- **ROC-AUC** : étudier le classement relatif des positifs et des négatifs, via les taux TPR et FPR.
- **Précision–rappel** : étudier combien de positifs sont trouvés et quelle proportion des alertes est correcte.

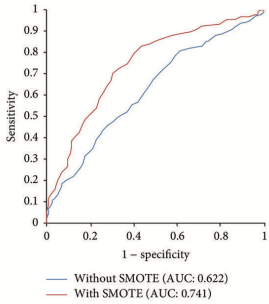
Si vous vous intéressez aux probabilités prédites

- Utiliser les probabilités $p(Y = 1 \mid x)$ ou, plus généralement, les **scores continus** du modèle.
- Faire varier le seuil pour observer les compromis possibles.
- **ROC-AUC** : étudier le classement relatif des positifs et des négatifs, via les taux TPR et FPR.
- **Précision–rappel** : étudier combien de positifs sont trouvés et quelle proportion des alertes est correcte.

Ces courbes évaluent la discrimination des scores. Elles ne vérifient pas que les probabilités sont bien calibrées.

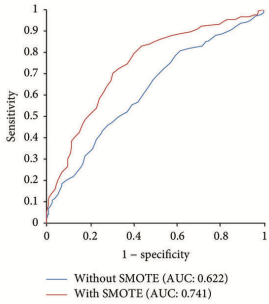
ROC-AUC : séparer les positifs des négatifs

- Abscisse : $FPR = FP/(FP + VN)$.



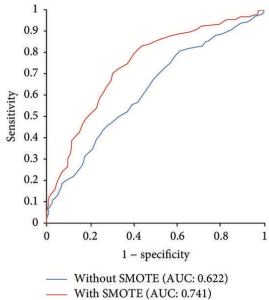
ROC-AUC : séparer les positifs des négatifs

- Abscisse : $FPR = FP/(FP + VN)$.
- Ordonnée : $TPR = VP/(VP + FN)$.



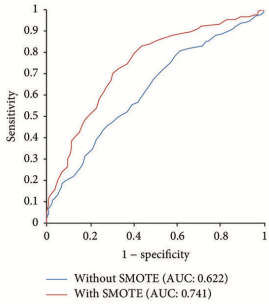
ROC-AUC : séparer les positifs des négatifs

- Abscisse : $FPR = FP/(FP + VN)$.
- Ordonnée : $TPR = VP/(VP + FN)$.
- Chaque seuil fournit un point de la courbe.



ROC-AUC : séparer les positifs des négatifs

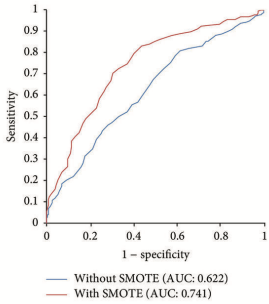
- Abscisse : $FPR = FP/(FP + VN)$.
- Ordonnée : $TPR = VP/(VP + FN)$.
- Chaque seuil fournit un point de la courbe.
- L'AUC résume la capacité globale à placer les positifs devant les négatifs, en comptant les égalités pour moitié.



ROC-AUC : séparer les positifs des négatifs

- Abscisse : $FPR = FP/(FP + VN)$.
- Ordonnée : $TPR = VP/(VP + FN)$.
- Chaque seuil fournit un point de la courbe.
- L'AUC résume la capacité globale à placer les positifs devant les négatifs, en comptant les égalités pour moitié.

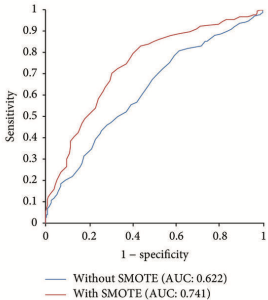
Utile pour examiner conjointement la détection des positifs et les fausses alertes parmi les négatifs.



ROC-AUC : séparer les positifs des négatifs

- Abscisse : $FPR = FP/(FP + VN)$.
- Ordonnée : $TPR = VP/(VP + FN)$.
- Chaque seuil fournit un point de la courbe.
- L'AUC résume la capacité globale à placer les positifs devant les négatifs, en comptant les égalités pour moitié.

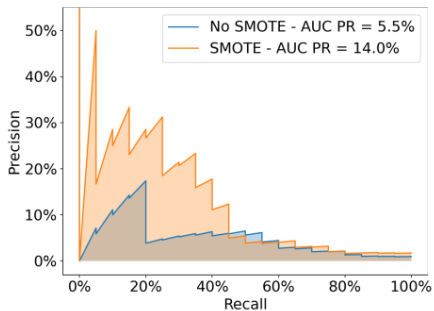
Utile pour examiner conjointement la détection des positifs et les fausses alertes parmi les négatifs.



Python : `roc_curve(y, scores)` et `roc_auc_score(y, scores)`.

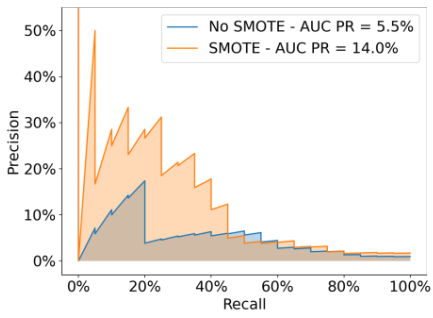
Précision–rappel : se concentrer sur la classe positive

- Abscisse : rappel $R = VP/(VP + FN)$.



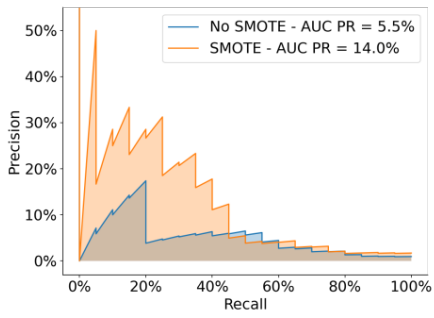
Précision–rappel : se concentrer sur la classe positive

- Abscisse : rappel $R = VP/(VP + FN)$.
- Ordonnée : précision $P = VP/(VP + FP)$.



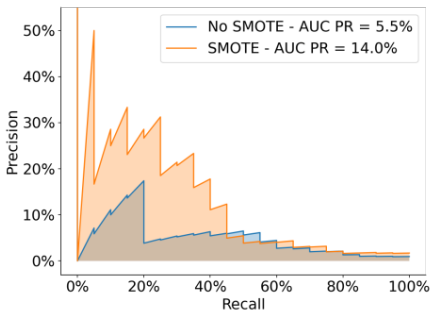
Précision–rappel : se concentrer sur la classe positive

- Abscisse : rappel $R = VP/(VP + FN)$.
- Ordonnée : précision $P = VP/(VP + FP)$.
- Faire varier le seuil produit la courbe PR.



Précision–rappel : se concentrer sur la classe positive

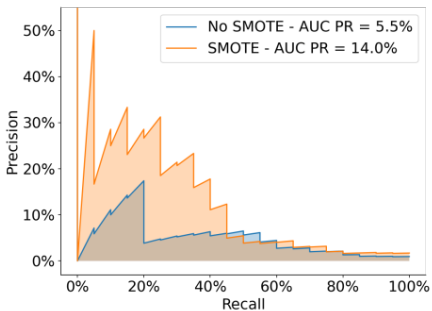
- Abscisse : rappel $R = VP/(VP + FN)$.
- Ordonnée : précision $P = VP/(VP + FP)$.
- Faire varier le seuil produit la courbe PR.
- Utile si les anomalies positives sont prioritaires : trouver les anomalies tout en limitant les alertes inutiles.



Précision–rappel : se concentrer sur la classe positive

- Abscisse : rappel $R = VP/(VP + FN)$.
- Ordonnée : précision $P = VP/(VP + FP)$.
- Faire varier le seuil produit la courbe PR.
- Utile si les anomalies positives sont prioritaires : trouver les anomalies tout en limitant les alertes inutiles.

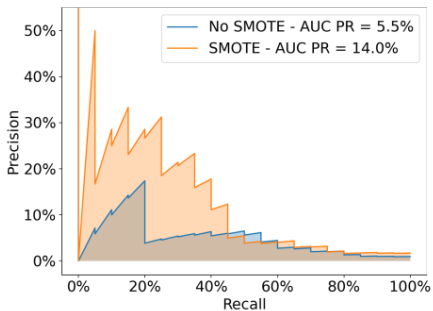
La précision dépend de la fréquence des anomalies : évaluer sur une distribution représentative.



Précision–rappel : se concentrer sur la classe positive

- Abscisse : rappel $R = VP/(VP + FN)$.
- Ordonnée : précision $P = VP/(VP + FP)$.
- Faire varier le seuil produit la courbe PR.
- Utile si les anomalies positives sont prioritaires : trouver les anomalies tout en limitant les alertes inutiles.

La précision dépend de la fréquence des anomalies : évaluer sur une distribution représentative.



Python : `precision_recall_curve(y, scores)`. Deux résumés possibles : AP ou aire par trapèzes, avec des conventions distinctes.

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	1/3	1

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	$1/3$	1
0,8	1	1	2	$1/3$	$1/2$

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	1/3	1
0,8	1	1	2	1/3	1/2
0,7	2	1	1	2/3	2/3

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	$1/3$	1
0,8	1	1	2	$1/3$	$1/2$
0,7	2	1	1	$2/3$	$2/3$
0,4	3	1	0	1	$3/4$

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	$1/3$	1
0,8	1	1	2	$1/3$	$1/2$
0,7	2	1	1	$2/3$	$2/3$
0,4	3	1	0	1	$3/4$
0,2	3	2	0	1	$3/5$

Construire la courbe PR : un exemple à cinq observations

Scores décroissants : 0,9 (+), 0,8 (−), 0,7 (+), 0,4 (+), 0,2 (−).

Trois positifs et deux négatifs. Prédire positif si $s \geq \tau$.

Seuil τ	VP	FP	FN	Rappel R	Précision P
$> 0{,}9$	0	0	3	0	1 (convention)
0,9	1	0	2	$1/3$	1
0,8	1	1	2	$1/3$	$1/2$
0,7	2	1	1	$2/3$	$2/3$
0,4	3	1	0	1	$3/4$
0,2	3	2	0	1	$3/5$

Une observation négative diminue la précision sans augmenter le rappel. Une observation positive augmente le rappel.

Calculer l'Average Precision (AP)

À partir des mêmes cinq scores, parcourus par ordre décroissant :

$$\boxed{AP = \sum_i (R_i - R_{i-1}) P_i}$$

Calculer l'Average Precision (AP)

À partir des mêmes cinq scores, parcourus par ordre décroissant :

$$\boxed{AP = \sum_i (R_i - R_{i-1}) P_i}$$

Le rappel augmente uniquement lorsqu'on inclut un positif. Chaque positif ajoute ici $1/3$ au rappel.

Calculer l'Average Precision (AP)

À partir des mêmes cinq scores, parcourus par ordre décroissant :

$$AP = \sum_i (R_i - R_{i-1}) P_i$$

Le rappel augmente uniquement lorsqu'on inclut un positif. Chaque positif ajoute ici $1/3$ au rappel.

Score du positif ajouté	Gain de rappel	Précision obtenue
0,9	$1/3$	1
0,7	$1/3$	$2/3$
0,4	$1/3$	$3/4$

Calculer l'Average Precision (AP)

À partir des mêmes cinq scores, parcourus par ordre décroissant :

$$\boxed{AP = \sum_i (R_i - R_{i-1}) P_i}$$

Le rappel augmente uniquement lorsqu'on inclut un positif. Chaque positif ajoute ici $1/3$ au rappel.

Score du positif ajouté	Gain de rappel	Précision obtenue
0,9	$1/3$	1
0,7	$1/3$	$2/3$
0,4	$1/3$	$3/4$

$$AP = \frac{1}{3} \times 1 + \frac{1}{3} \times \frac{2}{3} + \frac{1}{3} \times \frac{3}{4} = \frac{29}{36} \simeq \boxed{0{,}806}$$

Calculer l'Average Precision (AP)

À partir des mêmes cinq scores, parcourus par ordre décroissant :

$$\boxed{AP = \sum_i (R_i - R_{i-1}) P_i}$$

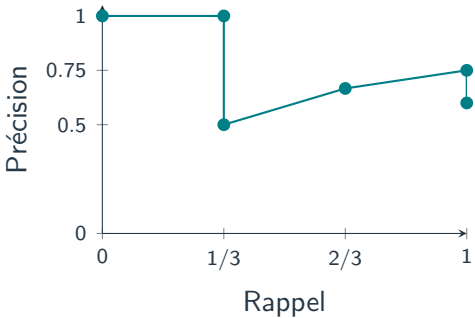
Le rappel augmente uniquement lorsqu'on inclut un positif. Chaque positif ajoute ici $1/3$ au rappel.

Score du positif ajouté	Gain de rappel	Précision obtenue
0,9	$1/3$	1
0,7	$1/3$	$2/3$
0,4	$1/3$	$3/4$

$$AP = \frac{1}{3} \times 1 + \frac{1}{3} \times \frac{2}{3} + \frac{1}{3} \times \frac{3}{4} = \frac{29}{36} \simeq \boxed{0{,}806}$$

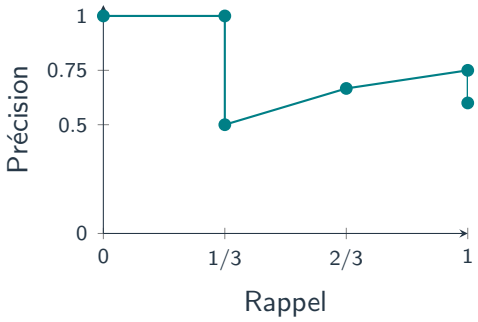
Python : `average_precision_score(y, scores)`. En l'absence d'ex æquo, c'est aussi la moyenne des précisions aux rangs occupés par les positifs.

Aire PR par trapèzes : une autre convention



On relie les points PR par des segments et on additionne les trapèzes :

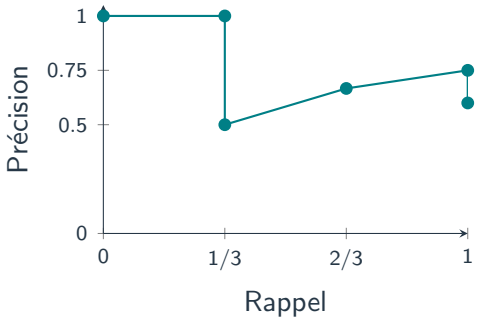
Aire PR par trapèzes : une autre convention



On relie les points PR par des segments et on additionne les trapèzes :

$$A_{PR} = \sum_i (R_i - R_{i-1}) \frac{P_i + P_{i-1}}{2}$$

Aire PR par trapèzes : une autre convention

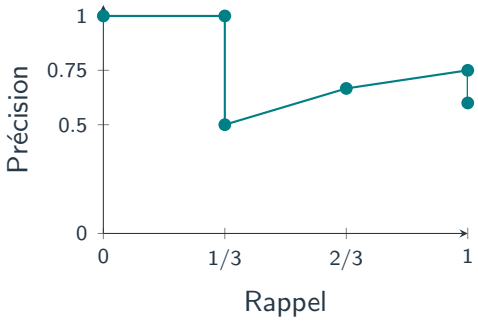


On relie les points PR par des segments et on additionne les trapèzes :

$$A_{PR} = \sum_i (R_i - R_{i-1}) \frac{P_i + P_{i-1}}{2}$$

$$= \frac{1}{3} + \frac{7}{36} + \frac{17}{72} = \frac{55}{72} \simeq 0{,}764$$

Aire PR par trapèzes : une autre convention



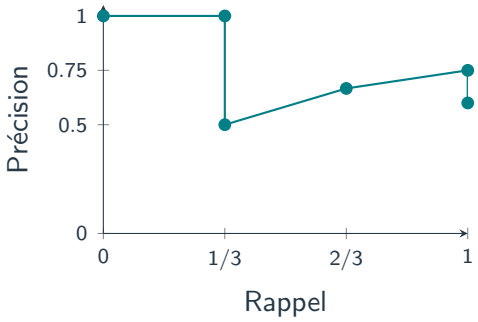
On relie les points PR par des segments et on additionne les trapèzes :

$$A_{PR} = \sum_i (R_i - R_{i-1}) \frac{P_i + P_{i-1}}{2}$$

$$= \frac{1}{3} + \frac{7}{36} + \frac{17}{72} = \frac{55}{72} \simeq 0{,}764$$

Les segments verticaux ont une aire nulle.

Aire PR par trapèzes : une autre convention



On relie les points PR par des segments et on additionne les trapèzes :

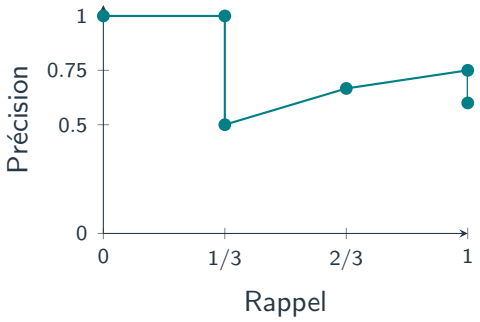
$$A_{PR} = \sum_i (R_i - R_{i-1}) \frac{P_i + P_{i-1}}{2}$$

$$= \frac{1}{3} + \frac{7}{36} + \frac{17}{72} = \frac{55}{72} \simeq 0{,}764$$

Les segments verticaux ont une aire nulle.

Sur le même classement : AP = 0,806, aire PR trapézoïdale = 0,764. Toujours préciser la convention utilisée.

Aire PR par trapèzes : une autre convention



On relie les points PR par des segments et on additionne les trapèzes :

$$A_{PR} = \sum_i (R_i - R_{i-1}) \frac{P_i + P_{i-1}}{2}$$

$$= \frac{1}{3} + \frac{7}{36} + \frac{17}{72} = \frac{55}{72} \simeq 0{,}764$$

Les segments verticaux ont une aire nulle.

Sur le même classement : AP = 0,806, aire PR trapézoïdale = 0,764. Toujours préciser la convention utilisée.

Python : `p, r, t = precision_recall_curve(y, scores)`, puis `auc(r, p)`.

Une bonne AUC aide à rechercher un seuil utile

- Une bonne ROC-AUC indique que les positifs sont généralement placés devant les négatifs.

Une bonne AUC aide à rechercher un seuil utile

- Une bonne ROC-AUC indique que les positifs sont généralement placés devant les négatifs.
- Le seuil 0,5 n'est pas nécessairement celui qui maximise le F1, la balanced accuracy ou le bénéfice métier.

Une bonne AUC aide à rechercher un seuil utile

- Une bonne ROC-AUC indique que les positifs sont généralement placés devant les négatifs.
- Le seuil 0,5 n'est pas nécessairement celui qui maximise le F1, la balanced accuracy ou le bénéfice métier.
- Chercher un meilleur seuil sur validation ne change ni le classement des scores ni la ROC-AUC.

Une bonne AUC aide à rechercher un seuil utile

- Une bonne ROC-AUC indique que les positifs sont généralement placés devant les négatifs.
- Le seuil 0,5 n'est pas nécessairement celui qui maximise le F1, la balanced accuracy ou le bénéfice métier.
- Chercher un meilleur seuil sur validation ne change ni le classement des scores ni la ROC-AUC.

Sur l'exemple à cinq observations :

Seuil	Précision	Rappel	F_1
0,5	$2/3$	$2/3$	$2/3 \simeq 0{,}667$
0,4	$3/4$	1	$6/7 \simeq 0{,}857$

Une bonne AUC aide à rechercher un seuil utile

- Une bonne ROC-AUC indique que les positifs sont généralement placés devant les négatifs.
- Le seuil 0,5 n'est pas nécessairement celui qui maximise le F1, la balanced accuracy ou le bénéfice métier.
- Chercher un meilleur seuil sur validation ne change ni le classement des scores ni la ROC-AUC.

Sur l'exemple à cinq observations :

Seuil	Précision	Rappel	F_1
0,5	$2/3$	$2/3$	$2/3 \simeq 0{,}667$
0,4	$3/4$	1	$6/7 \simeq 0{,}857$

Choisir le seuil selon la métrique métier. Le seuil 0,5 peut déjà être optimal : l'amélioration n'est pas garantie.

Évaluation : deux points d'attention

- Ne pas évaluer le modèle sur un échantillon artificiellement équilibré.

Évaluation : deux points d'attention

- Ne pas évaluer le modèle sur un échantillon artificiellement équilibré.
- Les anomalies peuvent apparaître sous des formes complètement nouvelles : un modèle supervisé peut manquer des anomalies sur lesquelles il n'a pas été entraîné.